Análisis avanzado de datos para marketing digital.

Gonzalo Esteban Sánchez

April 2026

1. Motivación

En el ecosistema actual del marketing digital, existe una saturación de herramientas y plataformas especializadas en publicidad *online*. Si bien la segmentación de audiencias se ha convertido en un proceso altamente automatizado gracias a gigantes como **Facebook Ads** o **Google Ads**, esta eficiencia conlleva un costo de oportunidad crítico: la pérdida de control sobre el conocimiento profundo del cliente.

1.1. El problema de la «caja negra»

Los algoritmos de estas plataformas son capaces de desplegar anuncios personalizados con una precisión asombrosa; sin embargo, operan frecuentemente como modelos de **caja negra**. Como anunciantes, a menudo obtenemos resultados positivos sin comprender realmente los criterios subyacentes de la segmentación o el porqué de la afinidad de un usuario con un anuncio específico. Esta opacidad oculta información vital sobre el perfil real del *buyer persona*, delegando la inteligencia de negocio a sistemas externos de terceros.

1.2. Objetivos del Trabajo

El propósito de esta investigación no es simplemente alcanzar una segmentación perfecta, sino **reivindicar la capacidad de inferencia** sobre nuestra propia base de datos. Los objetivos principales se centran en:

- **Análisis de Rendimiento:** Identificar con claridad en qué sectores o nichos específicos ha funcionado mejor una campaña u otra.
- **Segmentación Transparente:** Implementar una estrategia de segmentación propia y auditable utilizando algoritmos de **aprendizaje no supervisado** (*Unsupervised Learning*).
- **Generación de Insights:** Extraer patrones de comportamiento que permitan definir perfiles de clientes de forma independiente a las herramientas comerciales.

1.3. Metodología Propuesta

Para lograr una segmentación robusta y técnicamente fundamentada, se explorará el uso y comparativa de los siguientes modelos:

1. **K-means:** Para establecer agrupaciones basadas en la proximidad a centroides.
2. **DB-SCAN:** Para identificar segmentos basados en la densidad de los datos, permitiendo detectar patrones irregulares y valores atípicos (*outliers*).
3. **Self-Organizing Maps (SOM):** Para visualizar y categorizar datos de alta dimensionalidad en mapas bidimensionales, facilitando la interpretación de perfiles complejos.

   Conclusión: Este enfoque busca transformar datos brutos en conocimiento accionable, permitiendo que la estrategia de marketing se base en el entendimiento real del cliente y no solo en la ejecución automatizada de algoritmos opacos.

1.4. Descripción del dataset

El análisis se realiza sobre el dataset público *Customer Personality Analysis*, disponible en Kaggle bajo el identificador `imakash3011/customer-personality-analysis`. El dataset recoge información sociodemográfica, de consumo y de respuesta a campañas de marketing directo de una empresa minorista.

Cuadro 1: Resumen del dataset original

Característica	**Valor**	**Observaciones**
Número de observaciones	2.240	Clientes únicos
Número de variables	29	Antes del preprocesamiento
Variables numéricas	25	Incluyendo variables de campaña
Variables categóricas	3	Education, Marital_Status, Dt_Customer
Valores nulos	24	Únicamente en la variable Income
Variable objetivo	Response	Respuesta a la última campaña (0/1)

Las variables se pueden agrupar en cuatro bloques temáticos:

- **Perfil sociodemográfico:** año de nacimiento, nivel educativo, estado civil, ingresos anuales, número de hijos y adolescentes en el hogar, y fecha de alta como cliente.
- **Comportamiento de compra:** gasto en seis categorías de producto (vinos, frutas, carne, pescado, dulces y productos de lujo), número de compras realizadas por canal (web, catálogo, tienda física) y número de compras con descuento.

- **Historial de campañas:** indicadores binarios de aceptación para cinco campañas anteriores (`AcceptedCmp1`–`AcceptedCmp5`) y la variable `Response`, que registra la respuesta a la campaña más reciente y actúa como variable de validación en la evaluación económica final.
- **Variables de control:** `Recency` (días desde la última compra), `Complain` (reclamaciones en el último año) y dos variables constantes (`Z_CostContact`, `Z_Revenue`) que son eliminadas durante el preprocesamiento.

2. Análisis de datos

2.1. Análisis SOM

En este SOM, hemos incluido los resultados de las campañas anteriores. En la siguiente gráfica podemos observar las zonas más activas para las diferentes campañas anteriores. Es muy interesante incluir los resultados de campañas

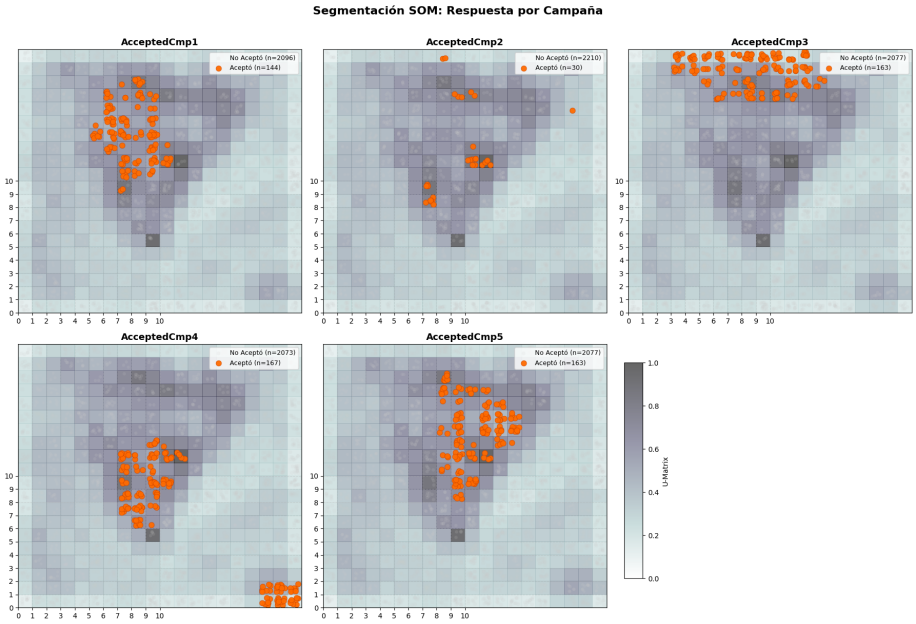

Figura 1: Aceptación de las campañas dentro del SOM.

anteriores, ya que al añadir estas variables dicotómicas en el análisis se puede observar cómo afloran patrones relevantes para esta zona de acción, como se aprecia en el siguiente mapa de calor.
Se puede observar que la zona donde se han activado las campañas anteriores coincide con la zona de activación de la columna **Income**, con las columnas de datos de consumo **Mnt...** y con datos de compra como **NumStorePurchases** o **NumCatalogPurchases**

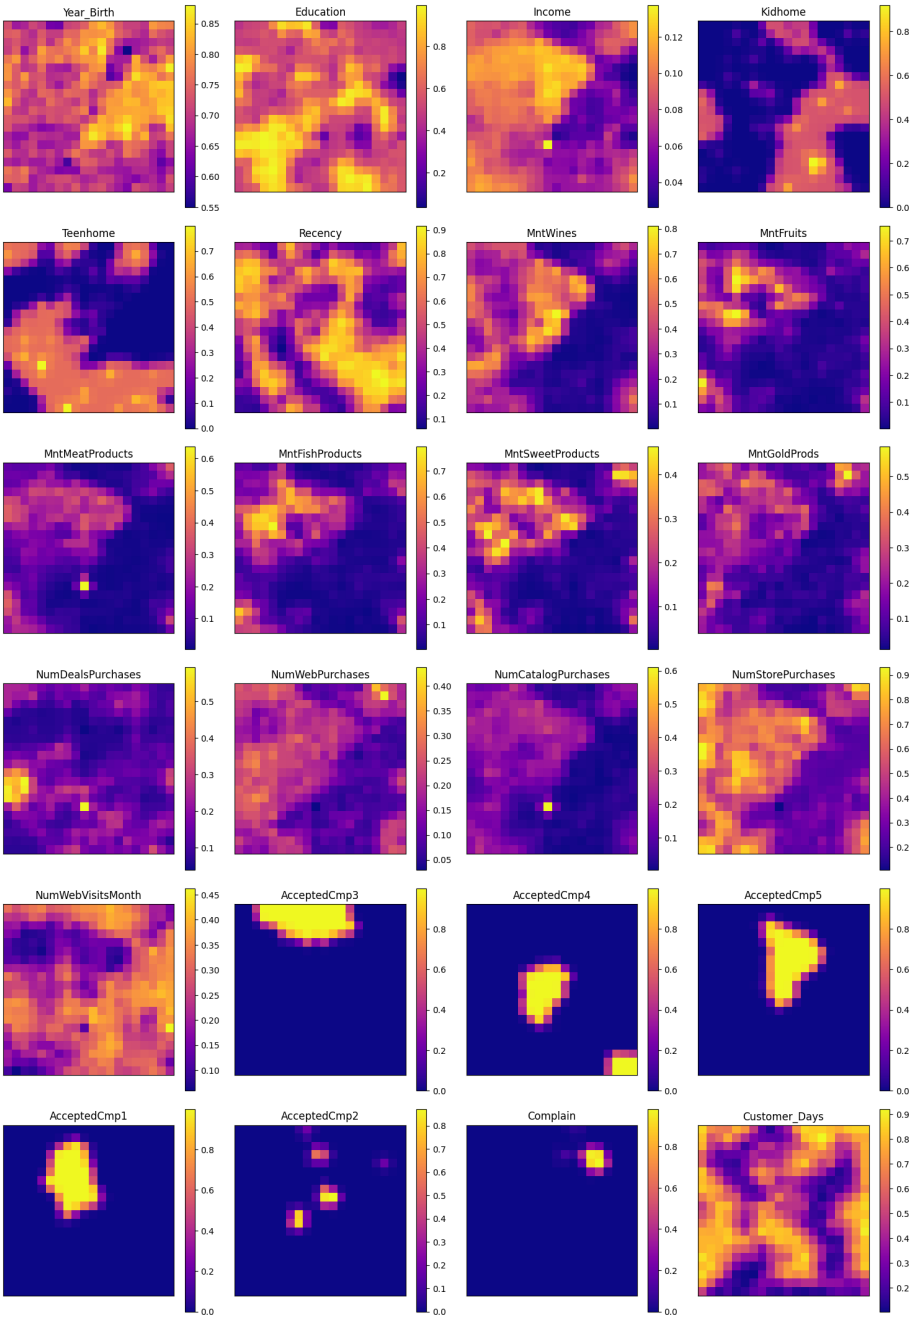

Figura 2: Mapas de calor por *feature*.

2.2. Análisis de variables a partir de modelos supervisados

En esta sección se han generado diferentes modelos predictivos basados en árboles y se han graficado sus importancias.

La importancia para los modelos basados en árboles nos indica cómo de buenas son estas variables a la hora de realizar particiones, es decir, cuánta entropía están reduciendo al dividir los datos. Como se observa en la gráfica, el SOM asig-

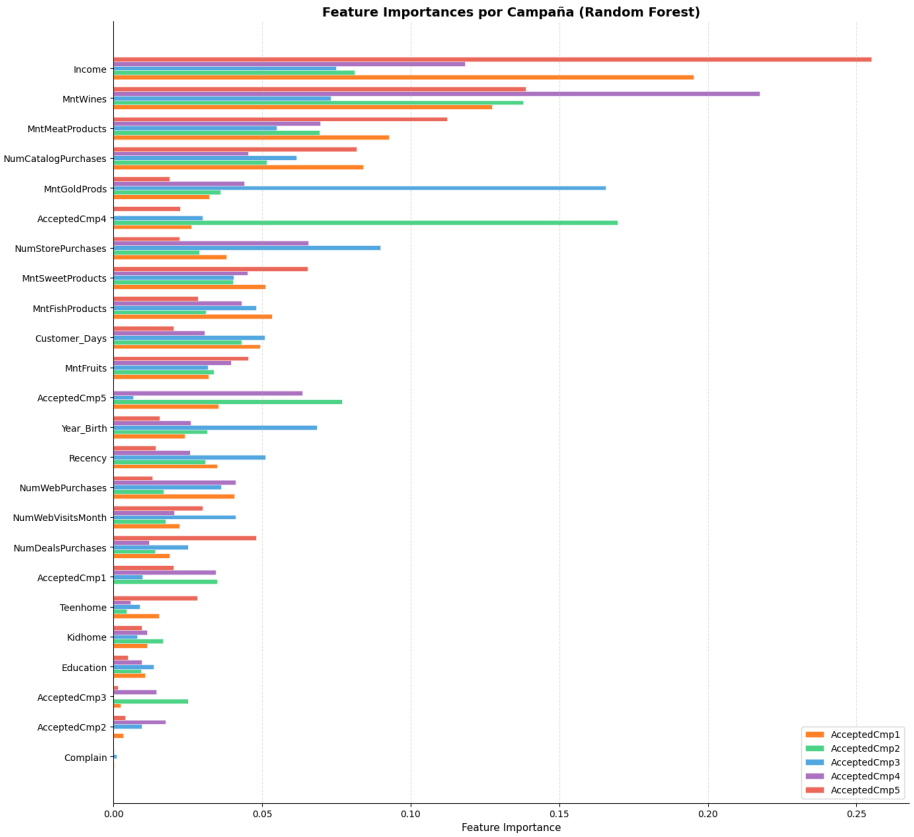

Figura 3: Importancia de las *features* por campaña (Random Forest).

na la zona de aceptación de las campañas a la zona donde se están activando las *features* que los modelos predictivos basados en árboles consideran importantes. Para terminar de analizar cómo de influyentes son estas *features* para las campañas, hemos implementado una técnica llamada SHAP values que nos muestra, en la parte alta de la gráfica, cuáles han sido las *features* más relevantes a la hora de predecir.

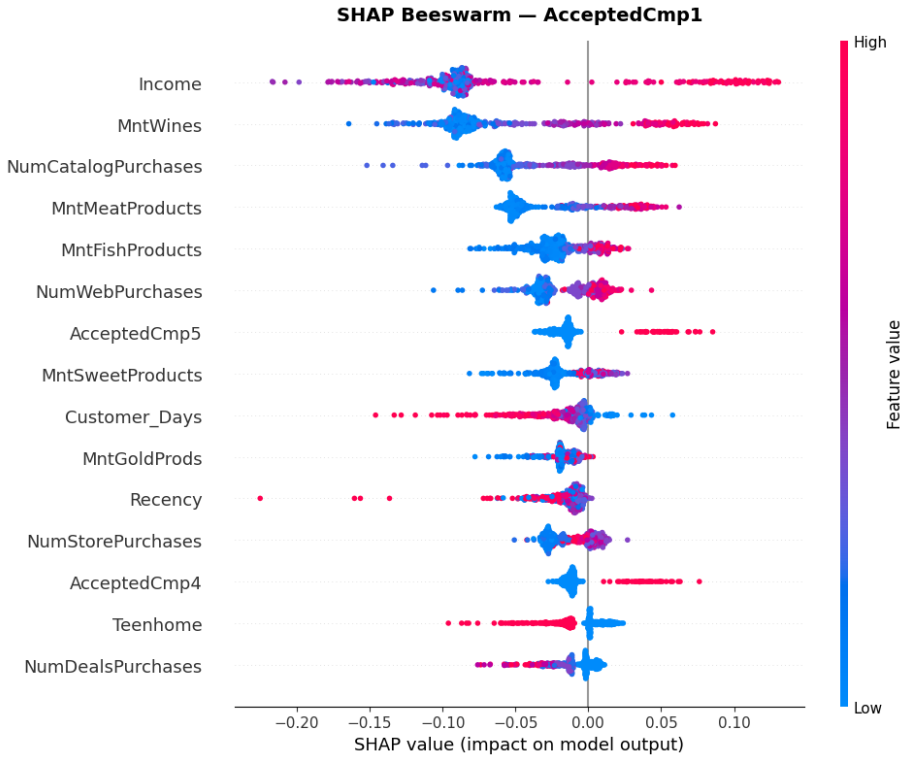

Figura 4: SHAP Values de la campaña 1.

2.3. Análisis de PCA

Para poder analizar el conjunto de datos y cuáles son las columnas que más influyen a la hora de aceptar una campaña, nos fijamos en las cargas de las columnas y las observaciones: aquellas que aparecen de color más oscuro corresponden a usuarios que han aceptado más campañas.

Como se puede observar en la gráfica, las columnas que apuntan hacia la zona de nuestros mejores usuarios son aquellas que habíamos considerado importantes anteriormente.
Sin embargo, lo más importante es que variables como **Kidhome**, **NumWebVisitsMonth**, **Teenhome**, **Year_Birth**, **Complain** o **Education** apuntan directamente en sentido contrario a nuestras columnas principales, o bien son perpendiculares a estas.

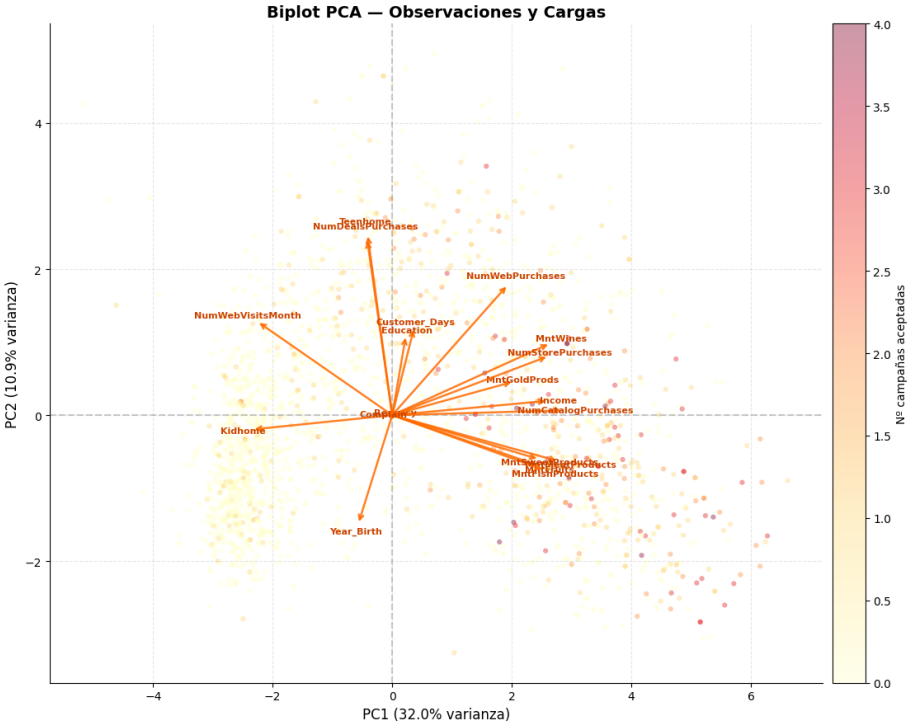

Figura 5: *Biplot* PCA: proyección conjunta de observaciones y cargas de las variables sobre las dos primeras componentes principales.

3. Segmentación de clientes y análisis de resultados

Una vez entrenado el SOM, aprovechamos su capacidad de proyección topológica para construir distintas estrategias de segmentación. Se comparan cuatro aproximaciones, combinando dos algoritmos de *clustering* (K-means y DBSCAN) con dos espacios de representación: las coordenadas de las neuronas del SOM (`-SOM`) y los datos originales estandarizados (`-OBS`). Cada cliente queda asignado al *cluster* de su BMU en el primer caso, o directamente al *cluster* de su vector de características en el segundo.

3.1. Visualización de los clusters obtenidos

Para cada uno de los cuatro modelos se muestra a continuación la proyección de los *clusters* sobre las dos primeras componentes principales (PCA), que permite valorar la separación de los grupos en el espacio original, junto con su distribución sobre la rejilla del SOM, que evidencia la coherencia topológica de la segmentación.

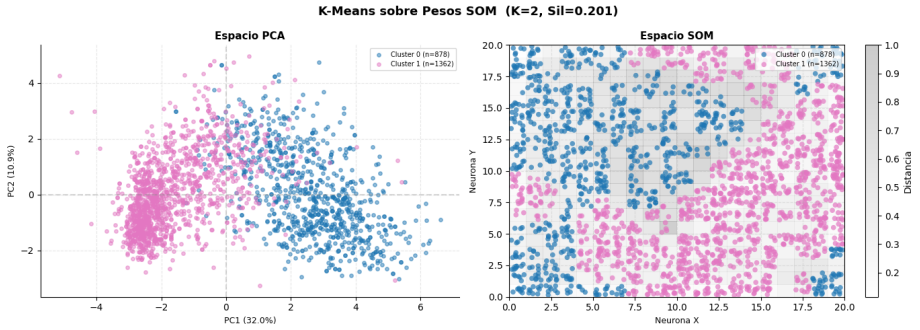

Figura 6: Modelo **KM-SOM**: proyección PCA y mapa SOM de los *clusters* obtenidos al aplicar K-means sobre las coordenadas de las neuronas.

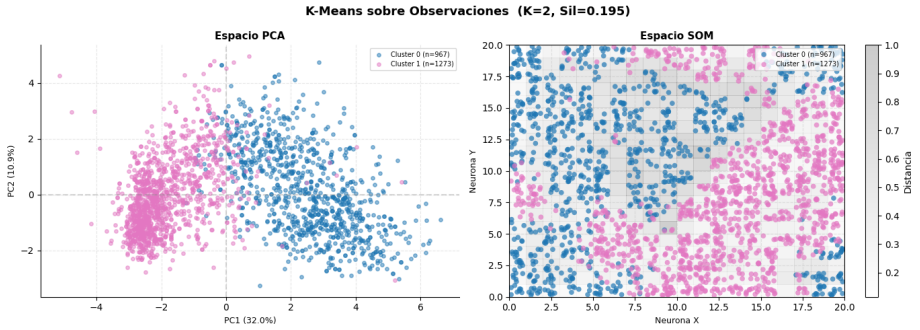

Figura 7: Modelo **KM-OBS**: proyección PCA y mapa SOM de los *clusters* obtenidos al aplicar K-means directamente sobre las observaciones estandarizadas.

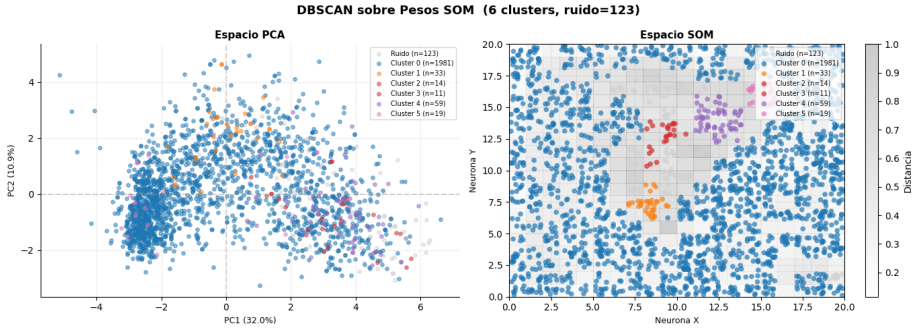

Figura 8: Modelo **DB-SOM**: proyección PCA y mapa SOM de los *clusters* obtenidos al aplicar DBSCAN sobre las neuronas del SOM. Los puntos etiquetados como ruido (`-1`) corresponden a las regiones de baja densidad del mapa.

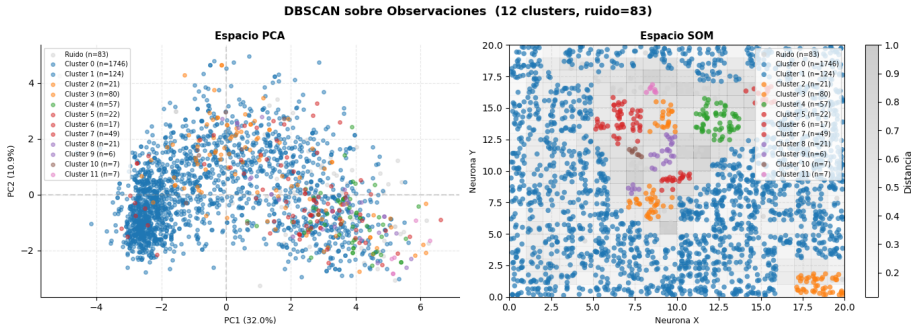

Figura 9: Modelo **DB-OBS**: proyección PCA y mapa SOM de los *clusters* obtenidos al aplicar DBSCAN directamente sobre las observaciones. Se aprecia un mayor número de microsegmentos respecto a DB-SOM.

3.2. Evaluación económica de la campaña

Para evaluar la utilidad práctica de cada segmentación se simula una campaña de *marketing* directo sobre la base de 2240 clientes. Se asume un coste de contacto de 3 € por cliente y un beneficio de 11 € por cada cliente que acepta la oferta (`Response` = 1). Como referencia, se incluye el escenario *baseline* consistente en contactar a la totalidad de la base, sin segmentación previa.

Para cada modelo se inspecciona la tasa de conversión por *cluster* y se seleccionan únicamente aquellos grupos cuya proporción de respondedores supera de forma clara la tasa global ($\approx 14{,}9\,\%$), de modo que el coste de contacto quede compensado por el beneficio esperado.

3.2.1. Distribución de respuesta por cluster

Cluster	N obs	% base	% Response = 1
KM-SOM			
0	878	39.2 %	23.9 %
1	1362	60.8 %	9.1 %
KM-OBS			
0	967	43.2 %	21.9 %
1	1273	56.8 %	9.6 %
DB-SOM			
0	1981	88.4 %	10.9 %
1	33	1.5 %	27.3 %
2	14	0.6 %	85.7 %
3	11	0.5 %	81.8 %
4	59	2.6 %	35.6 %
5	19	0.8 %	5.3 %
ruido	123	5.5 %	53.7 %
DB-OBS			
0	1746	77.9 %	8.3 %
1	124	5.5 %	43.5 %
2	21	0.9 %	66.7 %
3	80	3.6 %	13.8 %
4	57	2.5 %	36.8 %
5	22	1.0 %	45.5 %
6	17	0.8 %	5.9 %
7	49	2.2 %	26.5 %
8	21	0.9 %	85.7 %
9	6	0.3 %	33.3 %
10	7	0.3 %	42.9 %
11	7	0.3 %	57.1 %
ruido	83	3.7 %	45.8 %

Cuadro 2: Tamaño y tasa de conversión de los *clusters* obtenidos por cada modelo.

Las soluciones basadas en K-means producen únicamente dos grupos de gran tamaño que apenas duplican la tasa de conversión del grupo mayoritario, mientras que DBSCAN, tanto sobre el SOM como sobre las observaciones, identifica microsegmentos con tasas de conversión muy elevadas (superiores al 40 % y, en algunos casos, al 80 %). Esta granularidad es clave para una campaña rentable.

3.2.2. Resultados económicos

En la Tabla 3 se resume el resultado de seleccionar, en cada modelo, los *clusters* con mayor tasa de respuesta. Para K-means se utiliza el *cluster* 0, y para DBSCAN se incluyen todos los grupos densos junto con el ruido, dado que

este último presenta también una conversión muy por encima de la media.

Modelo	Contactados	% base	Aceptaron	Conversión	Beneficio neto	ROI
BASELINE	2240	100.0 %	334	14.9 %	−3046 €	−45,3 %
KM-SOM	878	39.2 %	210	23.9 %	−324 €	−12,3 %
KM-OBS	967	43.2 %	212	21.9 %	−569 €	−19,6 %
DB-SOM	259	11.6 %	118	45.6 %	+521 €	+67,1 %
DB-OBS	**494**	**22.1 %**	**189**	**38.3 %**	**+597 €**	**+40,3 %**

Cuadro 3: Comparativa económica de las estrategias de segmentación frente al *baseline* de contactar a toda la base.

3.3. Discusión

El *baseline* es claramente deficitario: contactar indiscriminadamente a los 2240 clientes genera unas pérdidas de 3046 €, ya que el coste de los contactos infructuosos supera ampliamente el beneficio aportado por los respondedores. Las cuatro estrategias de segmentación mejoran este resultado, pero con diferencias muy notables.

Los modelos basados en K-means (KM-SOM y KM-OBS) reducen las pérdidas en torno a un 90 % respecto al *baseline*, pero no consiguen alcanzar la rentabilidad. La razón es que K-means, al imponer dos grupos compactos y de tamaño similar, mezcla en un mismo *cluster* clientes con perfiles muy distintos, diluyendo la tasa de conversión hasta valores ($\approx$ 22–24 %) insuficientes para cubrir el coste por contacto.

Los modelos basados en DBSCAN, en cambio, sí son rentables. DB-SOM logra el mejor ROI (+67,1 %) gracias a una segmentación muy selectiva: contactando únicamente al 11,6 % de la base se captura aproximadamente el 35 % de los respondedores totales. DB-OBS obtiene un beneficio neto ligeramente superior (+597 €) al ampliar el grupo objetivo al 22,1 % de la base, capturando más respondedores (189 frente a 118) a costa de una tasa de conversión menor y, por tanto, un ROI más bajo.

La elección entre DB-SOM y DB-OBS depende, por tanto, del criterio del negocio: DB-SOM maximiza la eficiencia por euro invertido y resulta preferible cuando el presupuesto es limitado, mientras que DB-OBS maximiza el beneficio absoluto cuando el objetivo es captar el mayor número posible de aceptaciones manteniendo la rentabilidad. En ambos casos, el SOM ha demostrado su utilidad: bien como espacio de representación previo al *clustering* (DB-SOM), bien como herramienta de visualización que permite validar la coherencia topológica de las segmentaciones obtenidas en el espacio original (DB-OBS).